

PERBANDINGAN EKOSISTEM SPARK DAN PANDAS PADA ARSITEKTUR MEDALLION UNTUK ANALISIS KORELASI PRODUKTIVITAS-PERTUMBUHAN EKONOMI

Eigi Arthamevia¹; Natasya Amavisca²; Abdillah Fikri Al Pome³; Arienta Khusnul Ananda⁴

Sains Data¹

Institut Teknologi Sumatera, Lampung Selatan, Indonesia¹

pusat@itera.ac.id¹

eigi.123450011@student.itera.ac.id¹; natasya.123450024@student.itera.ac.id²;

abdillah.123450062@student.itera.ac.id³; arienta.123450097@student.itera.ac.id⁴

Author Study Program² (if different institutions with author 1 separated)

Name of Author Institution, City, Country² (if different institutions with Author 1 separated)

Author Institution Website Address² (if different institutions with author 1 separated)

Author's E-mail² (if different institutions from Author 1 are separated)

(*) Corresponding Author

(Responsible for the Quality of Paper Content)



The creation is distributed under the Creative Commons Attribution-NonCommercial 4.0 International License.

Abstract—The availability of Sustainable Development Goals (SDGs) data has opened opportunities for large-scale analysis of global economic and labor indicators. However, the increasing volume and complexity of data require a processing framework capable of handling data efficiently while maintaining analytical quality. This study evaluates the implementation of Medallion Architecture using Apache Spark and compares its performance with a conventional Pandas-based pipeline. The dataset used was SDG Goal 8 data obtained from the United Nations Statistics Division, covering employment and economic growth indicators across multiple countries and years. The processing workflow was divided into Bronze, Silver, and Gold layers to support data ingestion, transformation, and analytical aggregation. The study also examined the relationship between labor productivity and economic growth using Pearson correlation analysis. The results indicate a strong positive relationship between labor productivity and GDP per capita growth with a correlation coefficient of 0.8248. Performance evaluation shows that Pandas achieved a faster execution time of 46.73 seconds compared with Apache Spark at 77.83 seconds for the dataset size used in this study. These findings suggest that while Spark provides a scalable architecture suitable for future expansion, Pandas remains more efficient for medium-scale datasets processed in a local environment.

Keywords: apache spark, big data analytics, medallion architecture, pandas, sdg 8.

Abstrak—Ketersediaan data Sustainable Development Goals (SDGs) memberikan peluang untuk melakukan analisis terhadap indikator ekonomi dan ketenagakerjaan dalam skala global. Namun, volume data yang besar dan struktur data yang kompleks memerlukan pendekatan pemrosesan yang mampu menjaga efisiensi sekaligus kualitas analisis. Penelitian ini mengevaluasi penerapan Arsitektur Medallion berbasis Apache Spark dan membandingkannya dengan pipeline konvensional menggunakan Pandas. Dataset yang digunakan berasal dari SDG Goal 8 United Nations Statistics Division yang memuat indikator pekerjaan layak dan pertumbuhan ekonomi dari berbagai negara dan periode waktu. Proses pengolahan data dibagi ke dalam lapisan Bronze, Silver, dan Gold untuk mendukung tahap ingesti, transformasi, serta agregasi analitik. Selain itu, dilakukan analisis hubungan antara produktivitas tenaga kerja dan pertumbuhan ekonomi menggunakan korelasi Pearson. Hasil penelitian menunjukkan adanya hubungan positif yang sangat kuat antara produktivitas tenaga kerja dan pertumbuhan ekonomi dengan nilai korelasi sebesar 0,8248. Dari sisi performa komputasi, Pandas mencatat waktu eksekusi 46,73 detik, lebih cepat dibandingkan Apache Spark

yang memerlukan 77,83 detik pada ukuran data yang digunakan. Temuan ini menunjukkan bahwa Spark menawarkan arsitektur yang lebih siap untuk skalabilitas, sedangkan Pandas masih lebih efisien untuk pemrosesan data berukuran menengah pada lingkungan lokal.

Kata Kunci: apache spark, arsitektur medallion, analisis big data, pandas, sdg 8.

PENDAHULUAN

Pasar tenaga kerja global mengalami transformasi struktural akibat kemajuan teknologi, ekspansi sektor jasa, dan globalisasi yang mempercepat perubahan komposisi lapangan kerja. Dalam konteks ini, pekerjaan layak (decent work) menempati posisi sentral sebagai instrumen pembangunan manusia yang mencakup empat pilar utama yang dirumuskan ILO: promosi hak-hak kerja, perluasan kesempatan kerja produktif, perlindungan sosial, dan dialog sosial inklusif [1]. Kesadaran akan pentingnya dimensi tenaga kerja dalam agenda global mendorong PBB menempatkan pekerjaan layak bersama pertumbuhan ekonomi sebagai SDG Goal 8, dengan 12 target terukur yang mencakup indikator dari tingkat pengangguran, produktivitas per tenaga kerja, hingga proporsi pekerja rentan.


Negara-negara anggota Gulf Cooperation Council (GCC), yang meliputi Arab Saudi, Uni Emirat Arab, Kuwait, Qatar, Bahrain, dan Oman, menghadirkan konteks penelitian yang khas. Pertumbuhan ekonomi kawasan ini sangat bergantung pada pendapatan hidrokarbon dan didominasi oleh sistem tenaga kerja migran yang tersegmentasi, sehingga mekanisme transmisi antara kualitas pekerjaan dan pertumbuhan ekonomi jangka panjang beroperasi secara berbeda dibandingkan negara berkembang konvensional [2]. Kesenjangan riset empiris untuk kawasan GCC inilah yang menjadi motivasi utama artikel yang ditelaah. Oleh karena itu, penelitian ini bertujuan untuk mengevaluasi kinerja komputasi antara Apache Spark dan Pandas menggunakan Arsitektur Medallion dalam memproses big data SDG 8, serta menganalisis korelasi antara produktivitas tenaga kerja dan pertumbuhan ekonomi pada negara-negara anggota Gulf Cooperation Council (GCC).

METODOLOGI PENELITIAN

Dataset utama bersumber dari United Nations Statistics Division berupa file Goal8.xlsx. Dataset ini memuat 255.761 baris observasi *time-series* untuk berbagai indikator ketenagakerjaan dan pertumbuhan ekonomi secara global, dengan kolom-kolom meliputi: *Goal*, *Target*, *Indicator*, *SeriesCode*, *GeoAreaCode*, *GeoAreaName*, *TimePeriod*, *Value*, serta atribut disagregasi seperti jenis kelamin dan kelompok usia. Cakupan dataset mencakup lebih dari 190 negara dengan rentang temporal 2000–2024 [1].

Pendekatan analitik dibangun menggunakan Arsitektur Medallion tiga lapisan dengan engine komputasi terdistribusi Apache Spark 3.x dan antarmuka PySpark. Arsitektur Medallion merupakan pola desain data yang mengorganisasi pemrosesan secara bertahap melalui lapisan Bronze, Silver, dan Gold, di mana kualitas data meningkat secara progresif di setiap lapisan [3]. Apache Spark dipilih sebagai engine komputasi utama karena kemampuan pemrosesan *in-memory* terdistribusi yang dirancang untuk menangani dataset berskala besar secara efisien dibandingkan pendekatan pemrosesan sekuensial [5].

Alur Kerja Proyek Analisis Big Data: Arsitektur Medallion & Benchmarking SDG 8 (Kelompok 26)



Lapisan Bronze difungsikan sebagai zona pendaratan (*landing zone*) untuk ingesti data mentah. File Goal8.xlsx dibaca menggunakan library *openpyxl* kemudian disimpan langsung ke format Parquet tanpa transformasi, guna mempertahankan integritas dan fidelitas data sumber asli. Lapisan Silver menjalankan operasi transformasi meliputi: (1) penghapusan data duplikat; (2) penanganan nilai kosong melalui imputasi median per kelompok negara-indikator; (3) normalisasi nama negara yang tidak konsisten; (4) standarisasi tipe data kolom numerik; serta (5) penambahan kolom kawasan geografis berdasarkan kode *GeoAreaCode* PBB. Output disimpan dalam format Parquet terpartisi berdasarkan Target SDG. Lapisan Gold menjalankan komputasi analitik tingkat tinggi mencakup agregasi rata-rata laju pertumbuhan GDP per kapita (indikator *NY_GDP_PCAP*, Target 8.1) per negara dan periode, serta pembentukan matriks korelasi antara produktivitas tenaga kerja dan pertumbuhan ekonomi.

Untuk mengukur kekuatan hubungan linier antara produktivitas tenaga kerja dan pertumbuhan ekonomi, digunakan persamaan korelasi Pearson [3] sebagai berikut:

$$r = \frac{n \sum xy - (\sum x)(\sum y)}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}}$$

Keterangan variabel :

r : Koefisien korelasi Pearson.

n : Jumlah pasangan data (ukuran sampel).

x : Nilai variabel pertama.

y : Nilai variabel kedua.

$\sum x$: Total penjumlahan dari seluruh nilai x .

$\sum y$: Total penjumlahan dari seluruh nilai y .

$\sum xy$: Jumlah dari hasil perkalian setiap nilai x dan y .

$(\sum x)^2$: Jumlah dari kuadrat setiap nilai x .


$(\sum y)^2$: Jumlah dari kuadrat setiap nilai y .

Sebagai pembanding, diimplementasikan pipeline sekuensial berbasis Pandas yang memuat keseluruhan dataset ke dalam memori utama tanpa distribusi dan menjalankan seluruh operasi secara serial [5]. Perbandingan performa difokuskan pada throughput (baris per detik) dan latensi total eksekusi end-to-end pada dataset yang identik.

HASIL DAN PEMBAHASAN

Tren Pertumbuhan Ekonomi Global

Dinamika indikator pertumbuhan ekonomi global (SDG 8.1.1) sepanjang periode pengamatan ditunjukkan melalui grafik pada Gambar X di bawah ini




Hasil visualisasi pada Gold Layer menunjukkan bahwa pertumbuhan ekonomi global mengalami fluktuasi sepanjang periode pengamatan. Pada awal tahun 2000-an pertumbuhan ekonomi sempat mencapai lebih dari 15%, kemudian secara bertahap mengalami penurunan dan bergerak pada rentang 0% hingga 5%.

Dua periode kontraksi ekonomi terlihat secara jelas. Penurunan pertama terjadi pada tahun 2008 yang bertepatan dengan krisis keuangan global. Penurunan kedua terjadi pada tahun 2020 dengan tingkat pertumbuhan mencapai sekitar -6%, yang menunjukkan dampak besar pandemi COVID-19 terhadap aktivitas ekonomi dunia. Setelah periode tersebut, perekonomian global mengalami pemulihan dan kembali bergerak pada wilayah positif hingga mencapai kestabilan pada kisaran 2% selama periode 2022–2024.

Perbandingan Pertumbuhan Ekonomi Antar negara

Analisis rata-rata pertumbuhan ekonomi menunjukkan adanya perbedaan yang cukup besar antar negara. Albania mencatat rata-rata pertumbuhan tertinggi dengan nilai mendekati 4,7%. Afghanistan menempati posisi berikutnya dengan pertumbuhan sedikit di atas 2%. Algeria berada pada kisaran 1,4%, sedangkan Andorra memiliki tingkat pertumbuhan terendah di bawah 1%. Hal ini dapat dilihat dari visualisasi bar chart negara dengan rata-rata pertumbuhan PDB per kapita tertinggi.



Perbedaan ini menunjukkan bahwa dinamika pertumbuhan ekonomi tidak berlangsung secara seragam. Faktor produktivitas, kondisi sosial, stabilitas politik, serta struktur ekonomi

masing-masing negara berpotensi memengaruhi capaian pertumbuhan yang berbeda.

Analisis Korelasi Produktivitas dan Pertumbuhan Ekonomi

Pada hasil perhitungan korelasi Pearson menghasilkan nilai sebesar 0,8248. Nilai tersebut menunjukkan hubungan positif yang sangat kuat antara produktivitas tenaga kerja dan pertumbuhan ekonomi.

Temuan ini mengindikasikan bahwa peningkatan produktivitas tenaga kerja cenderung diikuti oleh peningkatan pertumbuhan ekonomi. Negara yang mampu menghasilkan output ekonomi lebih tinggi melalui peningkatan produktivitas tenaga kerjanya memiliki kecenderungan untuk mencapai pertumbuhan ekonomi yang lebih baik dibandingkan negara dengan produktivitas yang rendah.

Hasil ini juga sejalan dengan berbagai penelitian sebelumnya yang menempatkan produktivitas tenaga kerja sebagai salah satu faktor utama dalam mendorong pertumbuhan ekonomi jangka panjang.

Evaluasi Performa Apache Spark dan Pandas

Perbandingan performa dilakukan menggunakan dataset yang sama dengan total 255.761 baris data.

Metrik	Pandas	Apache Spark
Total Baris	255.761	255.761
Waktu Eksekusi	46,73 detik	77,83 detik
Throughput	5.473,75 baris/detik	3.286,27 baris/detik

Hasil pengujian menunjukkan bahwa Pandas menghasilkan waktu eksekusi yang lebih singkat dibandingkan Apache Spark. Throughput yang dicapai Pandas juga lebih tinggi sehingga proses pengolahan data dapat diselesaikan lebih cepat.

Kondisi ini terjadi karena ukuran dataset yang digunakan masih dapat ditangani secara optimal oleh pemrosesan memori tunggal. Sementara itu, Apache Spark memerlukan overhead tambahan untuk mengelola proses distribusi dan koordinasi komputasi. Walaupun demikian, Spark tetap memiliki keunggulan dalam aspek skalabilitas apabila volume data meningkat secara signifikan pada masa mendatang.

KESIMPULAN

Penelitian ini berhasil menerapkan Arsitektur Medallion untuk pengelolaan data SDG

Goal 8 menggunakan Apache Spark dan Pandas. Implementasi tiga lapisan data memungkinkan proses pengolahan berlangsung secara lebih terstruktur mulai dari data mentah hingga menghasilkan informasi yang siap dianalisis.

Hasil analisis menunjukkan bahwa produktivitas tenaga kerja memiliki hubungan positif yang sangat kuat terhadap pertumbuhan ekonomi dengan nilai korelasi Pearson sebesar 0,8248. Temuan ini menguatkan pentingnya peningkatan produktivitas sebagai salah satu faktor yang berkontribusi terhadap pertumbuhan ekonomi berkelanjutan.

Dari sisi performa komputasi, Pandas memberikan hasil yang lebih baik dibandingkan Apache Spark pada ukuran dataset yang digunakan, dengan waktu eksekusi lebih cepat dan throughput yang lebih tinggi. Namun demikian, Apache Spark tetap menawarkan keunggulan dalam pengelolaan data berskala besar karena mendukung pemrosesan terdistribusi dan skalabilitas yang lebih baik. Oleh karena itu, pemilihan teknologi sebaiknya disesuaikan dengan karakteristik dan volume data yang akan diproses.

REFERENSI

- [1] H. Abdulrahim, M. Gebrail, M. Elhaj, dan J. Binsuwadan, "Sustainable Trends in Decent Work and Economic Growth: A Comprehensive Analysis of GCC Countries," *Sustain.*, vol. 17, no. 19, hal. 1–18, 2025, doi: 10.3390/su17198798.
- [2] I. L. Organization, *Transformative change and SDG 8*, 2023.
- [3] M. Kantardzic, *Data Mining: Concepts, Models, Methods, and Algorithms*. Hoboken, New Jersey: John Wiley & Sons, Inc, 2019.
- [4] D. D. Unaradjan, *Metode Penelitian Kuantitatif*. Jakarta: Penerbit Unika Atma Jaya, 2019.
- [5] M. Zaharia et al., "Apache Spark: A Unified Engine for Big Data Processing," *Commun. ACM*, vol. 59, no. 11, pp. 56–65, Nov. 2016, doi: 10.1145/2934664.

